week4 作业

习题 5.1

题目与数据

根据表 5.1 所给的训练数据集，利用信息增益比（C4.5 算法）生成决策树。

数据集如下：

序号	计数	年龄	收入	学生	信誉	归类：买计算机?
1	64	青	高	否	良	不买
2	64	青	高	否	优	不买
3	128	中	高	否	良	买
4	60	老	中	否	良	买
5	64	老	低	是	良	买
6	64	老	低	是	优	不买
7	64	中	低	是	优	买
8	128	青	中	否	良	不买
9	64	青	低	是	良	买
10	132	老	中	是	良	买
11	64	青	中	是	优	买
12	32	中	中	否	优	买
13	32	中	高	是	良	买
14	63	老	中	否	优	不买
15	1	老	中	否	优	买

合计 **1024** 个样本，其中「买」641 例、「不买」383 例。

计算过程

根结点

先计算经验熵：

$$H(D) = -\frac{641}{1024}\log_2\frac{641}{1024} - \frac{383}{1024}\log_2\frac{383}{1024} \approx 0.953711 \text{ bit}.$$

特征「年龄」

年龄取值	样本数	买 / 不买	子集熵 $H(D_v)$
青	384	128 / 256	0.918296
中	256	256 / 0	0
老	384	257 / 127	0.915670

$$H(D \mid \text{年龄}) = \frac{384}{1024}\times 0.918296 + \frac{256}{1024}\times 0 + \frac{384}{1024}\times 0.915670 \approx 0.687737,$$

$$g(D,\text{年龄}) = 0.953711 - 0.687737 = 0.265974, \qquad H_{\text{年龄}}(D) \approx 1.561278, \qquad g_R = \frac{0.265974}{1.561278} \approx 0.170357.$$

特征「收入」

收入取值	样本数	买 / 不买	子集熵 $H(D_v)$
高	288	160 / 128	0.991076
中	480	289 / 191	0.969719
低	256	192 / 64	0.811278

$$H(D \mid \text{收入}) = \frac{288}{1024}\times 0.991076 + \frac{480}{1024}\times 0.969719 + \frac{256}{1024}\times 0.811278 \approx 0.936115,$$

$$g(D,\text{收入}) = 0.953711 - 0.936115 = 0.017596, \qquad H_{\text{收入}}(D) \approx 1.527104, \qquad g_R = \frac{0.017596}{1.527104} \approx 0.011522.$$

特征「学生」

学生取值	样本数	买 / 不买	子集熵 $H(D_v)$
是	484	420 / 64	0.563526
否	540	221 / 319	0.976110

$$H(D \mid \text{学生}) = \tfrac{484}{1024} \times 0.563526 + \tfrac{540}{1024} \times 0.976110 \approx 0.781100,$$

$$g(D, \text{学生}) = 0.953711 - 0.781100 = 0.172612, \qquad H_{\text{学生}}(D) \approx 0.997842, \qquad g_R = \tfrac{0.172612}{0.997842} \approx 0.172985.$$

特征「信誉」：

信誉取值	样本数	买 / 不买	子集熵 $H(D_v)$
良	672	480 / 192	0.863121
优	352	161 / 191	0.994754

$$H(D \mid \text{信誉}) = \tfrac{672}{1024} \times 0.863121 + \tfrac{352}{1024} \times 0.994754 \approx 0.908370,$$

$$g(D, \text{信誉}) = 0.953711 - 0.908370 = 0.045342, \qquad H_{\text{信誉}}(D) \approx 0.928362, \qquad g_R = \tfrac{0.045342}{0.928362} \approx 0.048841.$$

四个特征的信息增益比汇总：

特征 A	条件熵 $H(D \mid A)$	信息增益 g	固有值 $H_A(D)$	增益比 g_R
年龄	0.687737	0.265974	1.561278	0.170357
收入	0.936115	0.017596	1.527104	0.011522
学生	0.781100	0.172612	0.997842	**0.172985**
信誉	0.908370	0.045342	0.928362	0.048841

「学生」的增益比最大，**根结点取「学生」**，按「是」「否」分为两个分支。

分支「学生 = 否」

$$H(D) = -\tfrac{221}{540}\log_2\tfrac{221}{540} - \tfrac{319}{540}\log_2\tfrac{319}{540} \approx 0.976110.$$

候选特征：年龄、收入、信誉

特征「年龄」

年龄取值	样本数	买 / 不买	子集熵 $H(D_v)$
青	256	0 / 256	0
中	160	160 / 0	0
老	124	61 / 63	0.999812

$H(D \mid \text{年龄}) = \frac{124}{540} \times 0.999812 \approx 0.229587, \qquad g = 0.976110 - 0.229587 = 0.746523,$

$H_{\text{年龄}}(D) \approx 1.517873, \qquad g_R = \frac{0.746523}{1.517873} \approx 0.491822.$

特征「收入」

收入取值	样本数	买 / 不买	子集熵 $H(D_v)$
高	256	128 / 128	1.000000
中	284	93 / 191	0.912315

$H(D \mid \text{收入}) = \frac{256}{540} \times 1 + \frac{284}{540} \times 0.912315 \approx 0.953884,$

$g = 0.976110 - 0.953884 = 0.022226, \qquad H_{\text{收入}}(D) \approx 0.998060, \qquad g_R = \frac{0.022226}{0.998060} \approx 0.022269.$

特征「信誉」

信誉取值	样本数	买 / 不买	子集熵 $H(D_v)$
良	380	188 / 192	0.999920
优	160	33 / 127	0.734253

$H(D \mid \text{信誉}) = \frac{380}{540} \times 0.999920 + \frac{160}{540} \times 0.734253 \approx 0.921204,$

$g = 0.976110 - 0.921204 = 0.054906, \qquad H_{\text{信誉}}(D) \approx 0.876716, \qquad g_R = \frac{0.054906}{0.876716} \approx 0.062627.$

增益比汇总：年龄 **0.491822**、收入 0.022269、信誉 0.062627，取「年龄」为分裂属性：

- 年龄 = 青（256 例，全为不买）→ 叶结点：不买；
- 年龄 = 中（160 例，全为买）→ 叶结点：买；
- 年龄 = 老（124 例，类别不纯）→ 继续分裂。

结点「学生 = 否，年龄 = 老」

$H(D) = -\frac{61}{124}\log_2\frac{61}{124} - \frac{63}{124}\log_2\frac{63}{124} \approx 0.999812.$

候选特征：收入、信誉（年龄已被父结点使用；且该结点中「收入」取值恒为「中」——124 例全部为收入 = 中 —— 其 $H_A(D)=0$、$g=0$，无法作为分裂特征）。

特征「信誉」：

信誉取值	样本数	买 / 不买	子集熵 $H(D_v)$
良	60	60 / 0	0
优	64	1 / 63	0.116115

$$H(D\mid \text{信誉})=\tfrac{64}{124}\times 0.116115\approx 0.059930,\qquad g=0.999812-0.059930=0.939882,$$

$$H_{\text{信誉}}(D)=-\left(\tfrac{60}{124}\log_2\tfrac{60}{124}+\tfrac{64}{124}\log_2\tfrac{64}{124}\right)\approx 0.999249,\qquad g_R=\tfrac{0.939882}{0.999249}\approx 0.940588.$$

取「信誉」为分裂属性：

- 信誉 = 良（60 例，全为买）→ 叶结点：买；
- 信誉 = 优（64 例：不买 63、买 1），无其他可再分特征，按多数表决 → 叶结点：不买。

3. 分支「学生 = 是」

$$H(D)=-\tfrac{420}{484}\log_2\tfrac{420}{484}-\tfrac{64}{484}\log_2\tfrac{64}{484}\approx 0.563526.$$

候选特征：年龄、收入、信誉。

特征「年龄」：

年龄取值	样本数	买 / 不买	子集熵 $H(D_v)$
青	128	128 / 0	0
中	96	96 / 0	0
老	260	196 / 64	0.805125

$$H(D\mid \text{年龄})=\tfrac{260}{484}\times 0.805125\approx 0.432505,\qquad g=0.563526-0.432505=0.131021,$$

$$H_{\text{年龄}}(D)\approx 1.451979,\qquad g_R=\tfrac{0.131021}{1.451979}\approx 0.090236.$$

特征「收入」

收入取值	样本数	买 / 不买	子集熵 $H(D_v)$
高	32	32 / 0	0
中	196	196 / 0	0
低	256	192 / 64	0.811278

$H(D \mid \text{收入}) = \frac{256}{484} \times 0.811278 \approx 0.429106, \qquad g = 0.563526 - 0.429106 = 0.134420,$

$H_{\text{收入}}(D) \approx 1.273237, \qquad g_R = \frac{0.134420}{1.273237} \approx 0.105574.$

特征「信誉」

信誉取值	样本数	买 / 不买	子集熵 $H(D_v)$
良	292	292 / 0	0
优	192	128 / 64	0.918296

$H(D \mid \text{信誉}) = \frac{192}{484} \times 0.918296 \approx 0.364283, \qquad g = 0.563526 - 0.364283 = 0.199244,$

$H_{\text{信誉}}(D) \approx 0.968984, \qquad g_R = \frac{0.199244}{0.968984} \approx 0.205621.$

增益比汇总：年龄 0.090236、收入 0.105574、信誉 0.205621，取「信誉」为分裂属性：

- 信誉 = 良（292 例，全为买）→ 叶结点：**买**；
- 信誉 = 优（192 例，类别不纯）→ 继续分裂。

结点「学生 = 是，信誉 = 优」( )

$H(D) = -\frac{128}{192}\log_2\frac{128}{192} - \frac{64}{192}\log_2\frac{64}{192} \approx 0.918296.$

候选特征：年龄、收入。

特征「年龄」：青（64 例，全买）、中（64 例，全买）、老（64 例，全不买），子集熵均为 0。

年龄取值	样本数	买 / 不买	子集熵 $H(D_v)$
青	64	64 / 0	0
中	64	64 / 0	0
老	64	0 / 64	0

$H(D \mid \text{年龄}) = 0, \qquad g = 0.918296 - 0 = 0.918296,$

$H_{\text{年龄}}(D) = -\left(3 \times \frac{64}{192} \log_2 \frac{64}{192}\right) = \log_2 3 \approx 1.584963, \qquad g_R = \frac{0.918296}{1.584963} \approx 0.579380.$

特征「收入」：中（64 例，全买）、低（128 例，买 64 / 不买 64），子集熵分别为 0、1。

收入取值	样本数	买 / 不买	子集熵 $H(D_v)$
中	64	64 / 0	0
低	128	64 / 64	1.000000

$H(D \mid \text{收入}) = \frac{128}{192} \times 1 \approx 0.666667, \qquad g = 0.918296 - 0.666667 = 0.251629,$

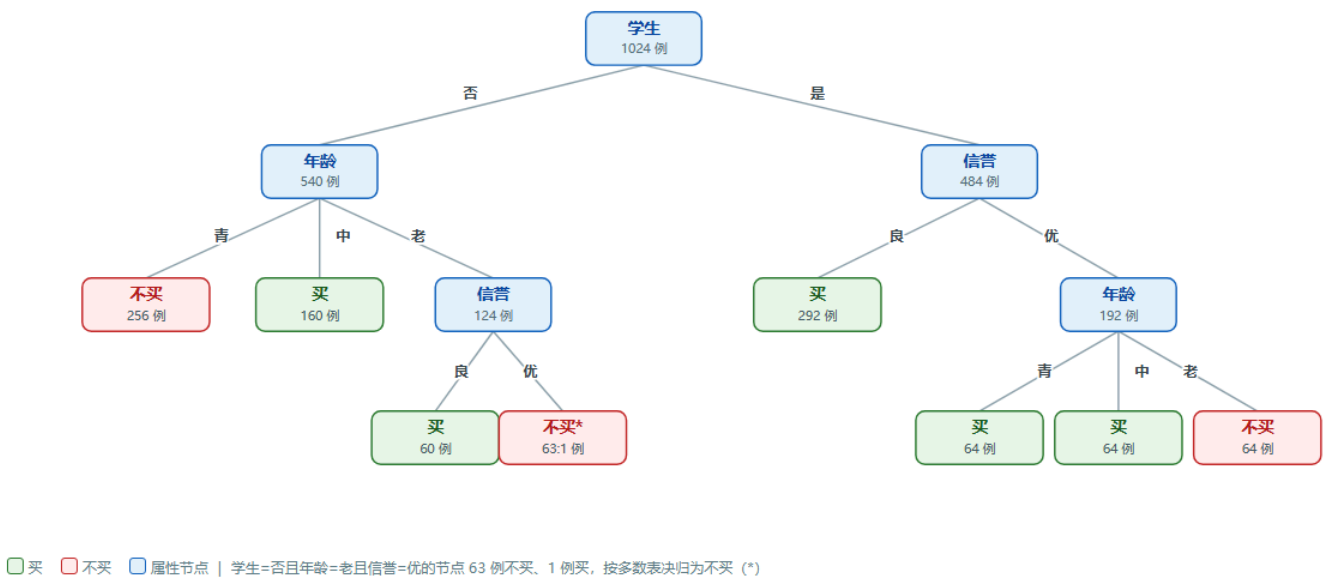
$H_{\text{收入}}(D) \approx 0.918296, \qquad g_R = \frac{0.251629}{0.918296} \approx 0.274018.$

「年龄」的增益比更大（0.579380 > 0.274018），取「年龄」为分裂属性：

- 年龄 = 青（64 例，全为买）→ 叶结点：买；
- 年龄 = 中（64 例，全为买）→ 叶结点：买；
- 年龄 = 老（64 例，全为不买）→ 叶结点：不买。

至此所有分支均到达叶结点，决策树生成完毕。

生成的决策树



树结构：

```
                        学生 (1024)
                ┌──────────┴──────────┐
            否 (540)                是 (484)
              │ 年龄                  │ 信誉
        ┌─────┼─────┐           ┌─────┴─────┐
        青    中    老          良          优
      不买   买   信誉      买(292)       年龄
    (256) (160)  ┌──┴──┐                ┌──┼──┐
                 良    优               青  中  老
                 买  不买*             买  买  不买
              (60)  (63:1)          (64)(64) (64)
```

决策规则：

```
学生 = 是 ?
├─ 信誉 = 良 ──────────────► 买
└─ 信誉 = 优
   ├─ 年龄 = 青 ──────────► 买
   ├─ 年龄 = 中 ──────────► 买
   └─ 年龄 = 老 ──────────► 不买
学生 = 否 ?
├─ 年龄 = 青 ──────────────► 不买
├─ 年龄 = 中 ──────────────► 买
└─ 年龄 = 老
   ├─ 信誉 = 良 ──────────► 买
   └─ 信誉 = 优 ──────────► 不买（63:1 多数表决）
```

5.2

题目与数据集

用平方误差损失准则生成二叉回归树（4 个叶节点）

x_i	1	2	3	4	5	6	7	8	9	10
y_i	4.50	4.75	4.91	5.34	5.80	7.05	7.90	8.23	8.70	9.00

解答

第一次切分（根节点）

对 $k = 1, 2, \ldots, 9$（$s = (x_k + x_{k+1})/2$）计算总平方误差，找到最小值：

切分点 s	左区域均值 c_1	右区域均值 c_2	总 SSE
1.5	4.500	6.851	17.53
2.5	4.625	7.166	13.18
3.5	4.720	7.513	8.83
4.5	4.875	7.837	5.66
5.5	5.060	8.176	3.359 ← 最小
6.5	5.467	8.456	5.87
7.5	5.893	8.643	9.37
8.5	6.329	8.850	13.10
9.5	6.759	9.000	16.66

最优切分：，即

- $R_1 = \{x \mid x \leq 5\}$，$c_1 = \dfrac{4.50 + 4.75 + 4.91 + 5.34 + 5.80}{5} = 5.06$
- $R_2 = \{x \mid x \geq 6\}$，$c_2 = \dfrac{7.05 + 7.90 + 8.23 + 8.70 + 9.00}{5} = 8.176$

第二次切分：在 R_1 和 R_2 中选增益更大者

- **SSE** $= (4.50-5.06)^2+\cdots+(5.80-5.06)^2 = 1.0582$
  - 最优切分 $s=3.5$：切分后 SSE $= 0.1912$
  - 增益=1.0582-0.1912=0.867
- **SSE** $= (7.05-8.176)^2+\cdots+(9.00-8.176)^2 = 2.3005$
  - 最优切分 $s=7.5$：切分后 SSE $= 0.6625$
  - 增益=2.3005-0.6625=1.638

R_2 的增益更大，故切分 R_2：

- $R_{21}=\{x \mid 6 \le x \le 7\}$，$c_{21}=\dfrac{7.05+7.90}{2}=7.475$
- $R_{22}=\{x \mid x \ge 8\}$，$c_{22}=\dfrac{8.23+8.70+9.00}{3}=8.643$

当前叶节点：R_1，R_{21}，R_{22}（共 3 个）。

第三次切分：再分裂一个叶节点（达到 4 个）

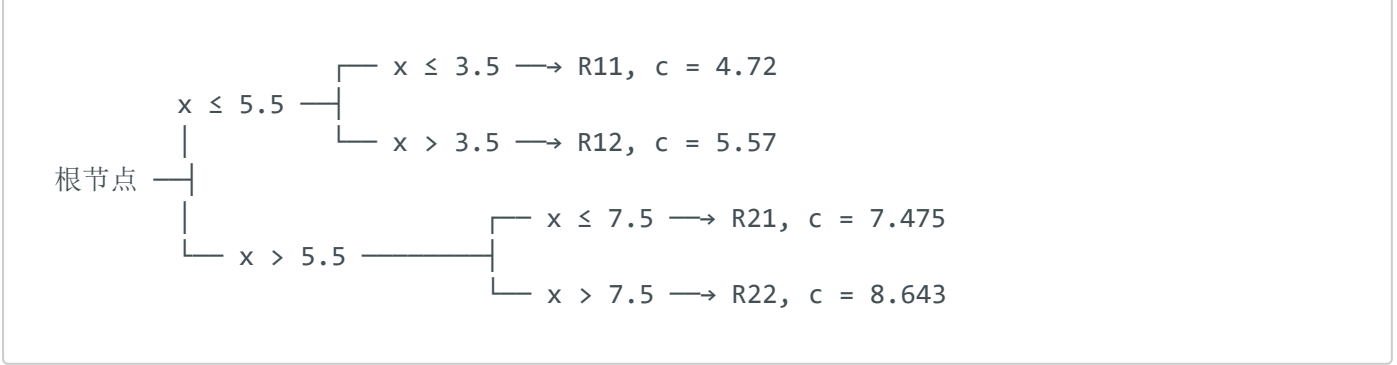
R_{21} 只有 2 个样本，无法再切。比较 R_1 与 R_{22}：

- R_1 切分增益 $= 0.867$
- R_{22} 的 SSE $= 0.3013$，最优切分 $s=8.5$ 后增益 $= 0.256$

切分 R_1（$s=3.5$）：

- $R_{11}=\{x \mid x \le 3\}$，$c_{11}=\dfrac{4.50+4.75+4.91}{3}=4.72$
- $R_{12}=\{x \mid 4 \le x \le 5\}$，$c_{12}=\dfrac{5.34+5.80}{2}=5.57$

最终回归树



回归方程：

$$f(x) = \begin{cases} 4.72, & x \le 3 \\ 5.57, & 4 \le x \le 5 \\ 7.475, & 6 \le x \le 7 \\ 8.64, & x \ge 8 \end{cases}$$

总平方误差 $= 0.1816 + 0.1096 + 0.3803 + 0.1822 \approx 0.854$。